林淑能

电话：18822320033 | **邮箱：**1477793103@qq.com | **微信：**kingdo_ai | **工作经验：**1 年

教育背景

2024.09-2027.06 **上海第二工业大学 & SCIT** **计算机技术(硕士)**

- **研究方向：**工业视觉检测与智能识别、机器视觉与图像处理
- **工程实践：**参与 PyTorch 模型从研发到落地的全流程，覆盖模型设计与训练优化、自动化标注流水线搭建、端到端推理系统开发及部署；具备 LLM 应用开发经验，设计并实现基于 RAG 与 Multi-Agent 架构的 AI 应用项目
- **学术成果：**北核论文 2 篇（已录用）、国家专利 1 项、软件著作权 2 项

2020.09–2024.06 **浙江工商大学** **数据科学与大数据技术（本科）**

- **主修课程：**人工智能技术及应用、神经网络、机器学习、图像处理与机器视觉、大数据技术与原理应用
- **荣誉奖项：**本科连续四年获奖学金，大创项目校级优秀结题

工作经历

2025.03-2026.3 **上海计算机软件技术开发中心** **AI 应用开发实习生**

- **视觉检测模型研发：**主导 **痰液肺癌细胞 AI 辅助诊断系统** 的 **视觉检测模型** 研发，基于 **RT-DETR** 架构优化轻量化主干网络与多尺度特征融合模块，设计双流交叉注意力机制，在私有病理数据集上 **mAP 提升约 26%。**
- **自动化标注系统搭建：**基于 **Label Studio** 构建模型自动标注流水线，部署 **ML Backend** 服务实现推理即标注功能，累计完成约 **8 万张病理切片图像** 的标注任务，大幅降低人工标注成本。
- **端到端推理流程开发：**封装检测模型为 **Flask** 推理服务，设计实现病理图像端到端自动推理流程，覆盖 **WSI 文件监听、切片生成与过滤、批量推理及结果上传**；自研坐标逆映射算法，实现局部检测结果到 WSI 全局坐标的还原。
- **模型部署与算力适配：**完成 **PyTorch** 模型向 **华为昇腾 910B (NPU)** 平台的适配与性能调优，实现单张数亿像素级病理图像 **5 分钟内** 完成全流程推理，推理效率较原生框架 **提升 73%。**
- **训练流程与实验管理：**实现医疗影像数据 **预处理、数据增强、超参数调优** 与模型训练策略优化，设计标准化实验记录与对比评估流程，提升模型迭代效率与结果可复现性。

项目经历

2025.12-2026.02 **To C 业务** **基于 RAG + Multi-Agent 的智能内容创作平台**

项目简介：面向内容创作场景的 AI 应用平台，基于 LangGraph 构建多 Agent 编排系统，结合 RAG 知识库、长期记忆和人机协作优化，实现文章创作、AI 封面图、剧情润色与文生视频在内的多模态内容创作。

技术栈：FastAPI、LangGraph、LangChain、Milvus、SQLAlchemy、SSE

- 设计并实现 LangGraph 多 Agent 编排引擎，封装 5 类 Agent，通过 8 维任务分析实现智能路由；引入质量门控节点，对首轮生成内容进行校验，未达标自动触发反思修订流程，实现单次请求内生成、检验及优化功能。
- 基于 **LangGraph** 搭建 5 类专业 **Agent**（ReAct、Reflection、Plan-and-Solve、RAG、Simple）状态机编排能力，按任务复杂度、实时性和知识依赖自动路由，覆盖问答、长文创作、知识增强生成等场景。
- 构建长期记忆与 **RAG** 知识库模块，支持情景记忆、语义记忆、程序记忆的跨会话共享，并接入文档上传、自动分块、Embedding、向量检索与 Milvus/内存双后端，提升内容生成的上下文连续性与知识复用能力。
- 集成联网搜索、事实核查、MCP Bridge、内容评估与反思修正功能，降低事实性内容幻觉风险；支持 **SSE** 流式输出、多 Agent 结果对比、封面图生成与剧情转视频等能力。
- 搭建 **FastAPI + React + 微信小程序** 三端架构，完成内容创作、对话、记忆管理等 API 设计与前后端联调，并通过 Docker Compose 实现一键部署。

2025.5-2025.8 **To B 业务** **面向 Agent 的模块化 RAG 知识检索平台**

项目简介：面向企业私有知识库问答场景，针对文档分散、关键词检索难以理解语义、AI 助手难以直接接入私有知识等问题，设计并实现模块化 RAG 检索与问答平台，支持文本与图像混合知识检索，并兼容 MCP 协议接入外部 Agent。

技术栈：RAG、MCP、ChromaDB、BM25、RRF、Cross-Encoder、Ragas

- 设计并实现 Load、Split、Transform、Embed、Upsert 五阶段 **Ingestion Pipeline**，支持 PDF 文档解析、语义切分、元数据增强、图片描述生成和增量摄取。
- 实现 **Dense Retrieval、BM25 和 RRF** 混合检索链路，并接入 **Cross-Encoder、LLM Rerank**，可在召回质量与响应效率之间做配置化权衡。
- 基于抽象接口、工厂模式、YAML 配置驱动，完成 LLM、Embedding、Vector Store、Reranker、Evaluator 等核心组件解耦，支持 OpenAI、Azure OpenAI、Ollama、DeepSeek 等多后端切换。
- 基于 **MCP** 协议实现知识检索服务，封装查询知识库、列表收集、获取文档摘要等工具，使 GitHub Copilot / Claude Desktop 等 Agent 可直接调用私有知识库。
- 构建可观测体系与 **Streamlit** 管理面板，覆盖 Ingestion Trace、Query Trace、数据浏览、评估分析等 6 类页面，并结合 **Ragas** 和自定义指标实现评估。

2025.01-2025.3　　To C 业务　　基于 LLM + 语音交互 的智能心血管健康管理平台

项目简介：基于 AI 技术构建智能心血管健康管理平台，通过机器学习模型进行疾病风险预测，结合可解释 AI、LLM 和智能语音问答等功能，为用户提供健康风险评估和个性化健康管理服务。

技术栈：FastAPI、XGBoost、SHAP、DeepSeek、CosyVoice、SQLite

- 完成数据清洗与特征工程，基于 **XGBoost** 训练心血管风险预测模型，准确率 86%、AUC 0.90；集成 **SHAP** 可解释性框架输出特征归因分析，实现 5 种可视化解释。
- 设计并实现置信度估计与模型对比模块，构建多轮对话与上下文记忆引擎，调用 **DeepSeek** 大模型与 **CosyVoice 语音合成**，实现文本与语音的双模式问答与情感识别接口。
- 负责随访计划、随访日历、会员与支付模拟、医生工作台、管理员后台等 20+ API 端点设计与开发。

项目成果：实现 **可解释 AI 预测、智能问答、健康卡片及随访管理** 等核心功能，并通过小规模测试验证用户价值假设。项目获校内外创新创业支持。

专业技能

- **LLM 应用与 RAG / Agent 编排：**掌握 **LangChain / LangGraph**，具备 **RAG** 构建、**Multi-Agent** 编排、**Prompt Engineering** 实战经验；有 **DeepSeek / GPT** 等主流大模型 **API 集成** 经验，能设计多轮对话、上下文记忆、长期记忆与知识检索系统；熟悉向量数据库（**Milvus**）、流式输出（**SSE**）、**Human-in-the-loop** 等 LLM 应用工程化方案。
- **AI 工程与全栈开发：**熟练掌握 **Python**，熟悉 **FastAPI、Flask** 等 Web 框架及 **SQLAlchemy ORM**；具备 **HTML5 / CSS3 / JavaScript** 基础，具备全栈开发与前后端联调能力；熟练掌握 **PyTorch**，具备模型训练调优到部署推理经验；具备自动化标注流水线搭建、大规模数据处理与高性能推理服务开发经验。
- **多模态 AI 能力：**具备计算机视觉（目标检测、图像处理）、语音合成（CosyVoice）与 LLM 结合的多模态应用开发经验，能将文本、图像、语音能力集成到统一的业务工作流中。
- **学术与认证：**北核论文 2 篇（基于改进 RT-DETR 的细胞检测算法、基于 yolo 的手势交互方法）、国家专利 1 项、软件著作权 2 项；HarmonyOS 应用开发者高级认证、CET-6；研究生二等奖学金（2025）、本科连续四年奖学金、大创校级优秀结题。

社交主页

- **Github 主页：**https://github.com/kingdoja
- **个人博客：**https://blog.csdn.net/m0_65266009